



<b>UNIDADE - FACULDADE DE COMPUTAÇÃO E INFORMÁTICA</b>		
<b>CURSO – CIÊNCIA DA COMPUTAÇÃO</b>		
<b>DISCIPLINA – Metodologia de Pesquisa em Computação</b>		<b>CÓDIGO DA DISCIPLINA</b>
<b>ALUNO</b> Gustavo Garabetti Munhoz	<b>DRT</b> 10409258	<b>ETAPA   TURMA</b> 6º   06N
<b>Proposta de Projeto, Orientador e Referências Bibliográficas</b>		<b>DATA</b> 19/Mar/2025

**TEMA:** *Smart Campus*: o uso de *Graph Neural Networks* (GNNs) na previsão de ocupação e fluxo de pessoas.

**ORIENTADOR:** Ivan Carlos Alcântara de Oliveira.

**PALAVRAS-CHAVE:** Convolutional networks, Deep learning, Traffic control, Traffic Forecasting, Neural Networks, Graph Neural Networks, Graph Data, Graph Convolutional Network, Convolutional Neural Network, Graph Representation Learning, Traffic flow, Smart City, IOT systems, Smart Campus.

**STRINGS DE BUSCA:**

"Convolutional networks" AND "traffic control" OR "traffic forecasting";  
"Neural networks" AND "graph neural networks" AND "graph data";  
"Graph convolutional network" AND "traffic control" AND "smart city";  
"Convolutional neural network" AND "graph representation learning";  
"Graph neural networks" OR "graph convolutional network" AND "traffic control";  
"Deep learning" AND "smart city" AND "IoT systems";  
"Convolutional networks" OR "neural networks" AND "smart city";  
"Graph representation learning" AND "traffic flow" OR "smart campus";  
"Deep learning" AND "traffic control" OR "traffic forecasting" AND "IoT systems";

**ARTIGOS:**

- CHEN, J., Ma, T., & XIAO, C. FastGCN: Fast learning with graph convolutional networks via importance sampling. **arXiv preprint arXiv:1801.10247**. 2018. Disponível em: <https://www-scopus-com.ez347.periodicos.capes.gov.br/record/display.uri?eid=2-s2.0-85083950469&origin=resultslist&sort=plf-f&src=s&sot=b&sdt=b&s=TITLE-ABS-KEY%28FastGCN%3A+Fast+learning+with+graph+convolutional+networks%29&relpos=1>. Data da Consulta: 22/03/2025.

Um dos instrumentos de pesquisa - as Redes Neurais baseadas em Grafos (GNNs) - foi idealizado para aprender com dados de treinamento e teste. No entanto, realizar buscas e expansões recursivas no grafo durante o treinamento pode ser custoso em termos de espaço e tempo para grafos densos. Para enfrentar essa limitação, o artigo propõe o uso de FastGCN, um esquema de dados em lote que visa tornar o treinamento da rede neural mais eficiente, reduzindo custos computacionais.



- LI, Y., YU, R., SHAHABI, C., & LIU, Y. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. **arXiv preprint arXiv:1707.01926**. 2018. Disponível em: <https://www-scopus-com.ez347.periodicos.capes.gov.br/record/display.uri?eid=2-s2.0-85083953652&origin=resultslist&sort=plf-f&src=s&sot=b&sdt=b&s=TITLE-ABS-KEY%28Diffusion+convolutional+recurrent+neural+network%3A+Data-driven+traffic+forecasting%29&sessionSearchId=a7dfb5bdfb59741c19ad80ad6fa58eab&relpos=2>. Data da Consulta: 22/03/2025.

Para enfrentar problemas decorrentes da modelagem de previsão espaço-temporal de tráfego, os pesquisadores deste artigo propuseram um modelo de fluxo de tráfego baseado em um processo de difusão em um dígrafo, juntamente com um framework de aprendizagem profunda. Tais componentes serão necessários para reduzir a complexidade de implementação desse modelo de rede neural em um campus inteligente.

- WU, Z., PAN, S., CHEN, F., LONG, G., ZHANG, C., & PHILIP, S. Y. A comprehensive survey on graph neural networks. **IEEE Transactions on Neural Networks and Learning Systems**, 32(1), 4-24. 2020. Disponível em: <https://ieeexplore-ieee-org.ez347.periodicos.capes.gov.br/document/9046288>. Data da Consulta: 22/03/2025.

Neste artigo, os autores apresentam uma visão abrangente sobre o uso de GNNs no aprendizado de máquina e mineração de dados, propondo uma taxonomia alternativa para os diferentes tipos de GNN, dentre os quais situam-se convoluções e previsão espacial-temporal, abordagens fundamentais para o projeto em questão.

- ZHANG, S., TONG, H., XU, J., & MACIEJEWSKI, R. Graph convolutional networks: A comprehensive review. **Computational Social Networks**, 6(1), 11. 2019. Disponível em: <https://www-webofscience-com.ez347.periodicos.capes.gov.br/wos/alldb/full-record/MEDLINE:37915858>. Data da Consulta: 22/03/2025.

Em contraste com o artigo mencionado imediatamente acima, este se preocupa em abordar de maneira mais específica os modelos convolucionais baseados em grafos, propondo novas classificações e explicando detalhadamente seu funcionamento e suas aplicações.

- GAO, T., & WANG, XM. Survey on traffic flow prediction methods based on graph convolution neural network. **Seventh international conference on traffic engineering and transportation system**, ICTETS 2023, Dalian, China, 2023. Disponível em: <https://www-webofscience-com.ez347.periodicos.capes.gov.br/wos/alldb/full-record/WOS:001200313300021>. Data da Consulta: 22/03/2025.

Admitindo-se que a predição e modelagem do fluxo de pessoas em um campus um é dos objetivos deste projeto de pesquisa, essa referência explora um problema semelhante aplicado ao trânsito nas cidades, apresentando experimentos e modelos de mensuração de resultados que podem servir de referência para a construção instrumental técnica do projeto.



- SILVA, Lucas Souza; ALCÂNTARA DE OLIVEIRA, Ivan Carlos. CROWD-RL: Ambiente Multiagente para Simulação de Fluxo de Atendimento. 2024. Disponível em: <https://aisel.aisnet.org/isla2024/15/>. Data da Consulta: 22/03/2025.

Para a realização do trabalho referenciado nesse artigo, foi desenvolvida uma biblioteca em Python que simula o fluxo de pessoas em ambientes de atendimento bem como a aplicação de algoritmos de sistemas multiagente para simulação. Dada a similaridade de aplicação dos projetos, o processo de desenvolvimento pode ser utilizado como referência.

- HAMILTON, W., et al. GraphSAGE: Inductive Representation Learning on Large Graphs. **NeurIPS**, 2023. Disponível em: <https://www.webofscience-com.ez347.periodicos.capes.gov.br/wos/alldb/full-record/WOS:000452649401007>. Data da Consulta: 22/03/2025.

Em um campus representado computacionalmente como um grafo, seus vértices mais notáveis, como os prédios das faculdades, secretarias, portarias e quadras, concentram uma grande quantidade de informações. Dada essa condição, este artigo propõe as aplicações e funcionamento de um framework construído para inferir informações de novos nós do grafo sem a necessidade de reprocessar o treinamento do modelo, economizando custo computacional.

- SANCHEZ-LENGELING, et al., "A Gentle Introduction to Graph Neural Networks", **Distill**, 2021. Disponível em: <https://distill.pub/2021/gnn-intro/>. Data da Consulta: 22/03/2025

Este artigo oferece uma introdução detalhada à importância do uso de Redes Neurais em grafos (GNNs) na resolução de diversos problemas do mundo real, servindo como um guia de apoio didático e abrangente para a aplicação dessas técnicas na elaboração do projeto em questão.

- DONG, Guimin et al. Graph neural networks in IoT: A survey. **ACM Transactions on Sensor Networks**, v. 19, n. 2, p. 1-50, 2023. Disponível em: [https://dl.acm.org/doi/abs/10.1145/3565973?casa\\_token=mLPSEnRGw4cAAAAA:a0\\_TlyGz\\_hmAwoPqIBqVthZ6a9XuDSoamAQ3atW2mIvkYDI5DRifTkeo7yJTHFZFvy\\_KeG8zTlxNa](https://dl.acm.org/doi/abs/10.1145/3565973?casa_token=mLPSEnRGw4cAAAAA:a0_TlyGz_hmAwoPqIBqVthZ6a9XuDSoamAQ3atW2mIvkYDI5DRifTkeo7yJTHFZFvy_KeG8zTlxNa). Data da Consulta: 22/03/2025.

Tendo em vista que o smart campus captura dados por meio de diversos sensores em um ambiente IOT integrado, tal referência é de extrema importância na exploração de como os GNNs podem ser incorporados nesses ambientes, capturando interações complexas em topologias de sensores e realizando buscas profundas nos dados fornecidos.

- H. Kim, B. S. Lee, W. -Y. Shin and S. Lim, "Graph Anomaly Detection With Graph Neural Networks: Current Status and Challenges," in **IEEE Access**, vol. 10, pp. 111820-111829,



2022,      doi:      10.1109/ACCESS.2022.3211306.      Disponível      em:  
<https://ieeexplore.ieee.org/abstract/document/9906987>. Data da Consulta: 22/05/2023.

Este estudo traz uma revisão geral atualizada de métodos de detecção de anomalias em grafos dinâmicos para sistemas complexos utilizando Redes Neurais baseadas em Grafos (GNNs). Essa abordagem é relevante para aplicação em um modelo de fluxo de pessoas em um smart campus, uma vez que grandes eventos, horários de entrada e saída, entre outros fatores, podem gerar anomalias no fluxo de pessoas em certos dias no ano letivo.