



Proposta 7.

Título: *Smart Campus*: o uso de *Graph Neural Networks* (GNNs) na previsão de ocupação e fluxo de pessoas.

Tipo: Iniciação Científica (IC) ou Trabalho de Conclusão de Curso (TCC)

Resumo: Este estudo explora o uso de *Graph Neural Networks* (GNNs) para prever a ocupação e o fluxo de pessoas em um *Smart Campus*, considerando os padrões temporais e espaciais nos dados de mobilidade. Com base no comportamento dos usuários, a aplicação de GNNs visa fornecer informações que apoiem a tomada de decisões e aprimorem o planejamento das operações no campus.

Problema de Pesquisa: como as *Graph Neural Networks* (GNNs) podem ser utilizadas para prever a ocupação e o fluxo de pessoas em um *Smart Campus*, considerando a variabilidade temporal e espacial dos dados de mobilidade?

Objetivo Geral: investigar a aplicação de *Graph Neural Networks* (GNNs) para a previsão de ocupação e fluxo de pessoas em um *Smart Campus* com base em dados de mobilidade e comportamento dos usuários buscando fornecer subsídios para uma gestão mais eficiente de espaços e recursos.

ODS Relacionada: 9 - Indústria, Inovação e Infraestrutura e 11 - Cidades e Comunidades Sustentáveis .

Metodologia:

- **Coleta de Dados e Estruturação de Dados de Mobilidade:** realização da coleta de dados através de sensores e dispositivos de monitoramento ou fazer a geração de dados sintéticos por meio de um simulador a respeito da movimentação e ocupação em tempo real.
- **Modelagem e Pré-processamento:** fazer a estruturação dos dados em grafos que representem a distribuição e movimentação das pessoas entre os diferentes espaços do campus.
- **Desenvolvimento e Treinamento do Modelo GNN:** implementação de modelos de GNN para processar dados temporais e espaciais, focando em padrões de ocupação e movimento de usuários. Posteriormente, realizar o treinamento das GNNs usando dados históricos para capturar e aprender padrões de fluxo e variação de ocupação.
- **Validação e Análise dos Resultados:** avaliação da precisão dos modelos em prever ocupação e fluxo em diferentes períodos e locais. Depois, analisar os resultados para identificar como as previsões podem ser integradas à gestão de espaços e à distribuição de recursos no campus.

Referências Bibliográficas

CHEN, J., Ma, T., & XIAO, C. *FastGCN: Fast learning with graph convolutional networks via importance sampling*. **arXiv preprint arXiv:1801.10247**. 2018.

HAMILTON, W., et al. GraphSAGE: Inductive Representation Learning on Large Graphs. **NeurIPS**, 2023.

KIPT, T. N., & WELLING, M. *Semi-supervised classification with graph convolutional networks*. **arXiv preprint arXiv:1609.02907**. 2016.



LI, J., Han, F., & QIAN, K. Graph neural networks and its application in smart city. ***Journal of Applied Mathematics and Computation***, 5(1), 28-37. 2021.

LI, Y., YU, Y., ZHANG, Z., & PENG, T. Graph neural network-based anomaly detection in smart campus IoT systems. ***IEEE Internet of Things Journal***, 8(1), 12-22. 2021.

LI, Y., YU, R., SHAHABI, C., & LIU, Y. *Diffusion convolutional recurrent neural network: Data-driven traffic forecasting*. **arXiv preprint arXiv:1707.01926**. 2018.

WU, Z., PAN, S., CHEN, F., LONG, G., ZHANG, C., & PHILIP, S. Y. *A comprehensive survey on graph neural networks*. **IEEE Transactions on Neural Networks and Learning Systems**, 32(1), 4-24. 2020.

ZHANG, S., TONG, H., XU, J., & MACIEJEWSKI, R. Graph convolutional networks: A comprehensive review. ***Computational Social Networks***, 6(1), 11. 2019.

ZHOU, J., CUI, G., ZHANG, Z., YANG, C., LIU, Z., WANG, L., LI, C., & SUN, M. *Graph neural networks: A review of methods and applications*. **AI Open**, 1, 57-81. 2020.